

Week 3 Report - Supervised Fraud Model & DTS

Device Trust Score - Track Supervised

1. Executive Summary

Trong tuần 3, track supervised đã hoàn thiện pipeline dự đoán gian lận, hiệu chỉnh xác suất gian lận và quy đổi sang thang Device Trust Score (DTS) 0-1000. Mục tiêu chính là tạo score có thể dùng cho review vận hành và có thể nộp theo format `CustomerID`, `P_fraud`, `DTS`.

Kết quả chính:

- Tập train có 51,047 khách hàng, trong đó 1,633 fraud, tương ứng tỷ lệ dương tính 3.20%.
- Tập holdout có 20,000 khách hàng, mỗi khách hàng có đúng một dòng score.
- Validation dùng stratified 5-fold, metric chính là PR-AUC và recall at 5% review.
- Model tốt nhất theo mean 5-fold PR-AUC là `stacking_tuned`, đạt PR-AUC 0.8203 và recall at 5% review 0.8310.
- Xác suất đầu ra được calibration bằng isotonic regression fit trên out-of-fold prediction, sau đó convert sang DTS bằng PDO.
- Có submission riêng cho từng model trong `outputs/supervised/submit/`.

2. Data & Feature Pipeline

Nguồn dữ liệu supervised gồm:

- `dts_train.csv`: bảng khách hàng train, chứa `FraudFlag`, `FraudType`, `Churn` và các biến thuê bao.
- `dts_holdout.csv`: bảng khách hàng holdout không có label.
- `sim_events`, `device_sessions`, `kyc_records`, `device_catalog`: log sự kiện SIM, session thiết bị, KYC và metadata thiết bị.

Feature matrix được build ở mức một dòng cho mỗi `CustomerID`. Các cột định danh/label không được dùng làm input model: `CustomerID`, `FraudFlag`, `FraudType`, `Churn`. Feature được mở rộng theo nhiều nhóm:

- Hành vi SIM: số lần swap, thời gian từ lần swap gần nhất, tín hiệu theo cửa sổ 7/30/90 ngày.
- Session/device: số session, active days, IP/country/cell diversity, home-cell ratio, shared-device.
- KYC: face match score, ID document match score, KYC level.
- Device catalog/TAC: low-tier, rooted, emulator/clone, shared IMEI/device, risk score.
- Device sharing: số customer liên kết với IMEI/TAC/device, max customers per IMEI.
- Biến phân loại được xử lý trong fold bằng WOE hoặc encoder tương ứng, tránh fit transform trên toàn bộ train trước khi split.

Design tránh leakage:

- Tất cả transform có học tham số, ví dụ imputer, scaler, WOE encoder, đều được fit bên trong từng fold.
- OOF prediction dùng cho calibration được tạo bằng model không nhìn thấy fold validation.
- Final model chỉ được fit lại trên toàn bộ train sau khi đã chọn hyperparameter/calibrator bằng quy trình OOF.

3. Validation Design

Validation dùng `StratifiedKFold(n_splits: 5)`. Stratification giữ tỷ lệ fraud gần ổn định trong từng fold, quan trọng vì fraud chỉ chiếm 3.20%.

Metric chính:

- PR-AUC: đo chất lượng ranking trong bối cảnh dương tính hiếm.
- Recall at 5% review: giả lập constraint vận hành, tức chỉ review 5% khách hàng rủi ro cao nhất.

Quy trình:

1. Tune hyperparameter bằng Optuna trên stratified 5-fold.
2. Với best hyperparameter, rerun K-fold để lấy OOF raw P_fraud cho toàn bộ train.
3. Fit isotonic calibrator trên OOF raw P_fraud và FraudFlag.
4. Fit final model trên toàn bộ train.
5. Predict raw P_fraud trên holdout.
6. Transform raw probability bằng calibrator, rồi convert sang DTS.

4. Model Experiments

Model	PR-AUC	Recall at 5%
stacking_tuned	0.8203	0.8310
lgbm_tuned	0.8166	0.8298
xgb_tuned	0.8160	0.8243
gbm_tuned	0.8084	0.8151
logistic_tuned	0.6953	0.7189

Interpretation:

- Logistic Regression là baseline dễ đọc hệ số, nhưng kém hơn rõ rệt vì quan hệ phi tuyến và tương tác device/KYC/graph rất quan trọng.
- GBM, LightGBM và XGBoost đều cải thiện mạnh PR-AUC, cho thấy tree-based models phù hợp với dữ liệu tabular nhiều ngưỡng và tương tác.
- Stacking tuned là model tốt nhất về PR-AUC tổng thể, nhưng chỉ nhỉnh hơn LightGBM tuned và XGBoost tuned 1 chút. Vì vậy LightGBM vẫn là candidate mạnh nếu cần triển khai đơn giản hơn hoặc cần explainability trực tiếp hơn.

5. Error Analysis By Fraud Archetype

Với stacking_tuned, recall at 5% review theo archetype:

FraudType	Count	Captured	Recall at 5%
sim_swap_ato	499	389	0.7796
mule	429	329	0.7669
device_farm	382	342	0.8953
subscription_fraud	323	296	0.9164

sim_swap_ato và mule là hai archetype có recall thấp nhất. Chúng có recall thấp hơn device_farm và subscription_fraud, dù mean score vẫn cao. Điều này hợp lý về nghiệp vụ: device_farm thường để lại tín hiệu shared-device/TAC/IP rõ hơn, còn sim_swap_ato và mule có thể giống hành vi khách hàng thật hoặc được phân tán qua nhiều thiết bị/session.

6. Calibration & DTS

Calibration được thực hiện bằng isotonic regression. Input của calibrator là OOF raw probability, target là FraudFlag thật. Cách này tránh leakage vì mỗi OOF probability được sinh ra bởi model không train trên chính record đó.

Sau calibration:

- P_fraud là xác suất đã hiệu chỉnh, dùng để so sánh absolute risk giữa khách hàng.
- DTS được quy đổi từ calibrated P_fraud theo PDO, với base score 600 và PDO 50.
- Quy ước: P_fraud càng cao thì DTS càng thấp; DTS được clip về [0, 1000].

Reliability curve được lưu tại:

- outputs/supervised/supervised_calibration_reliability_curve.csv

Holdout score đã lưu:

- outputs/supervised/supervised_holdout_calibrated_scores.csv

7. Explainability: SHAP & Reason Codes

Global SHAP được tính cho primary score model `stacking_tuned`. Vì stacking là ensemble custom, phần SHAP giải thích bằng model non-stacking tốt nhất là `lgbm_tuned`; report có hai cột `score_model_name` và `explaining_model_name` để ghi rõ điều này.

Top global SHAP features:

Rank	Feature	Mean SHAP
1	distinct_ip_count	0.3885
2	ServiceArea_woe	0.2586
3	id_doc_match_score	0.2408
4	home_cell_ratio	0.1467
5	distinct_country_count	0.1367
6	days_since_last_sim_swap	0.1360
7	face_match_score	0.1317
8	max_customers_per_imei	0.1219

Các feature quan trọng bám khá sát trực giác nghiệp vụ:

- `distinct_ip_count`, `distinct_country_count`: account có nhiều IP/quốc gia thường có rủi ro takeover hoặc vận hành bất thường.
- `id_doc_match_score`, `face_match_score`, KYC level: chất lượng định danh thấp kéo rủi ro lên.
- `days_since_last_sim_swap`, `sim_swap_count_total`: tín hiệu trực tiếp cho SIM swap/ATO.
- `max_customers_per_imei`, `num_accounts_linked_to_device`: shared-device/device-farm/mule network.

Local SHAP case studies đã tạo 3 case, mỗi archetype ít nhất một case:

CustomerID	FraudType	P_fraud	Top reason examples
3089538	sim_swap_ato	0.9895	days_since_last_sim_swap, distinct_ip_count, distinct_country_count
3000462	mule	0.9895	max_customers_per_imei, home_cell_ratio, num_accounts_linked_to_device
3196754	device_farm	0.9895	max_customers_per_imei, tac_risk_score, non_residential_ratio

Reason codes cho reviewer được sinh trên toàn bộ holdout và lưu tại:

- outputs/supervised/supervised_holdout_reason_codes.csv
- outputs/supervised/supervised_global_shap_importance.csv
- outputs/supervised/supervised_local_shap_case_studies.csv (các case được chọn trong train)

8. Submission Outputs

Đã sinh file nộp cho từng model tại outputs/supervised/submit/.

Model	Rows	File
logistic_tuned	20,000	logistic.csv

gbm_tuned	20,000	gbm.csv
lgbm_tuned	20,000	lgbm.csv
xgb_tuned	20,000	xgb.csv
stacking_tuned	20,000	stacking.csv

Schema mỗi file:

CustomerID, P_fraud, DTS

Trong đó P_fraud là calibrated probability và DTS là điểm PDO 0-1000.

9. Model Card

Intended Use

Model dùng để xếp hạng rủi ro fraud ở mức CustomerID, hỗ trợ review thủ công top-risk customers và tạo Device Trust Score.

Training Data

- Train: 51,047 CustomerID, unique.
- Fraud positive: 1,633 cases, tỷ lệ 3.20%.
- Holdout: 20,000 CustomerID, unique.
- Fraud archetypes trong train: sim_swap_ato, mule, device_farm, subscription_fraud.

Model Families

- Logistic Regression baseline.
- Gradient Boosting.
- LightGBM.
- XGBoost.
- Stacking ensemble với meta learner.

Hyperparameter tuning được thực hiện bằng Optuna. Class imbalance được xử lý qua class weight/scale-pos-weight và threshold/review-rate analysis.

Metrics

- Primary: PR-AUC.
- Operational: recall at 5% review.
- Calibration: reliability curve và Brier-style probability quality check trong notebook.
- Explainability: global SHAP, local SHAP case studies, reason codes.

Limitations

- Holdout không có FraudType, nên local archetype case studies phải lấy từ train.
- Stacking có explainability gián tiếp: SHAP dùng LightGBM tuned làm explaining model thay vì giải thích toàn bộ stacked object end-to-end.
- Calibration dựa trên historical distribution; nếu fraud mix, device ecosystem hoặc detection policy thay đổi, calibration có thể drift.

10. Checkpoint Questions

Vì sao PR-AUC phù hợp hơn ROC-AUC ở tỷ lệ dương tính 3.2%?

Với tỷ lệ fraud chỉ 3.2%, ROC-AUC có thể nhìn rất tốt dù model chưa đủ tốt ở vùng cần vận hành. Lý do là ROC dùng false positive rate: $FP / \text{total negatives}$. Khi negative class rất lớn, một lượng false positive lớn về số tuyệt đối vẫn có thể tạo FPR nhỏ. Điều này làm ROC-AUC ít nhạy với câu hỏi thực tế: trong nhóm bị review, có bao nhiêu fraud được bắt?

PR-AUC tập trung vào precision và recall của positive class. Nó trả lời đúng hơn bài toán fraud detection: khi model đưa khách hàng lên top-risk, tỷ lệ fraud trong nhóm đó là bao nhiêu và bắt được bao nhiêu fraud. Vì quy trình vận hành chỉ review 5% khách hàng rủi ro cao nhất, PR-AUC và recall at 5% review phản ánh trực tiếp chất lượng ranking trong vùng action được.

Calibration thay đổi gì khi DTS được dùng làm credit input?

Nếu DTS được dùng làm input cho credit/KYC decisioning, calibration trở nên quan trọng hơn ranking thuần túy. Một model chưa calibrated vẫn có thể rank đúng, nhưng xác suất 0.80 không nhất thiết nghĩa là rủi ro fraud thật gần 80%. Khi convert sang DTS, xác suất bị miscalibrated sẽ làm điểm bị kéo quá mạnh hoặc quá nhẹ, dẫn đến input tín dụng bị bias theo scale sai.

Calibration biến raw model score thành xác suất có ý nghĩa hơn về absolute risk. Điều này giúp:

- DTS phản ánh mức rủi ro theo thang ổn định hơn.
- Giảm nguy cơ over-penalize nhóm khách hàng chỉ vì model raw probability bị overconfident.

Tuy nhiên, calibration không tự cải thiện khả năng ranking của model và cũng không loại bỏ các bias có sẵn trong dữ liệu huấn luyện. Calibration chỉ giúp xác suất dự đoán phù hợp hơn với fraud rate quan sát được. Vì vậy, khi DTS được sử dụng như một input cho credit decision, cần tiếp tục giám sát model drift, calibration drift, fairness/proxy bias và độ ổn định của các DTS bucket theo thời gian. Đặc biệt, cần đảm bảo rằng calibrated P_{fraud} và DTS luôn có quan hệ monotonic hợp lý: P_{fraud} càng cao thì DTS càng thấp, đồng thời mỗi vùng điểm DTS vẫn phản ánh đúng mức rủi ro thực tế.