

Device Trust Score

Báo cáo tổng hợp

*Data understanding, feature engineering, Track A, Track B, scorecard,
decision matrix, PSI, fairness và explainability*

VDT VDS 2026

Họ và tên: Dương Minh Quân

Mục lục

1. Tóm tắt	3
2. Bối cảnh nghiệp vụ và mục tiêu	3
3. Dữ liệu, ERD và chất lượng dữ liệu	3
4. Feature engineering	4
5. Track A - Unsupervised	5
6. Track B - Supervised	6
7. Final model, calibration và DTS scorecard	7
8. Decision matrix cho KYC, Fraud Detection và Credit Input	8
9. PSI và stability	9
10. Fairness/proxy-bias diagnostic	10
11. Explainability và reason codes	11
12. Câu hỏi checkpoint week 4	12
13. Kết luận cuối kỳ	12
14. Câu hỏi phản biện	13
14.1. Tại sao Track A AUC cao hơn nhưng PR-AUC/precision lại thấp hơn?	13
14.2. Nguyên nhân <code>sim_swap_ato</code> giảm mạnh trong Track A blend là gì?	13
14.3. Nếu chỉ chọn baseline unsupervised hoặc blend unsupervised để production ngay, chọn cái nào? ..	14
14.4. Vì sao mule và subscription fraud gần như vô hình với anomaly detection?	14
14.5. Có nên đưa stacking vào production khi không tốt hơn XGBoost đáng kể?	14
14.6. GBM và XGB PR-AUC gần nhau nhưng Precision@5% lệch lớn nói lên điều gì?	14
14.7. Vì sao logistic có <code>Corr(P_fraud, DTS)</code> yếu hơn các model phi tuyến?	15
14.8. Calibration gap lớn nhất ở final model là bin nào và có ảnh hưởng credit input không?	15
14.9. Nếu chỉ đủ ngân sách triển khai rule-based/unsupervised hoặc supervised, nên chọn lộ trình nào? ..	15
14.10. Khi triển khai thật không có answer key ngay, monitoring model drift thế nào?	16

Danh mục hình ảnh

Hình 1 ERD dữ liệu đầu vào của bài toán Device Trust Score.	4
Hình 2 So sánh metric tổng hợp giữa Track A baseline, Track A blend và Track B XGB.	6
Hình 3 PR-AUC và Precision@5% của các mô hình Track B.	7
Hình 4 Reliability curve của <code>xgb_tuned</code> : xác suất sau calibration so với fraud rate thực tế theo bin.	7
Hình 5 Tỷ lệ action fraud trên holdout final sau khi áp dụng decision matrix.	9
Hình 6 Top feature PSI train-vs-holdout. Tất cả feature trong hình đều ở trạng thái stable.	10
Hình 7 Review/block rate theo các segment fairness/proxy-bias diagnostic.	11
Hình 8 Top 10 global SHAP feature importance từ output explainability.	12

Danh mục bảng

Bảng 1 Danh sách các bảng dữ liệu hệ thống đầu vào	3
Bảng 2 Cấu trúc cấu thành 4 trụ cột tính năng (Feature Pillars)	5
Bảng 3 Hiệu năng tổng quát của các thuật toán Unsupervised Track A	5
Bảng 4 Recall theo FraudType @ review 4% đối với Track A	5
Bảng 5 Hiệu năng định lượng các mô hình Supervised Track B	6
Bảng 6 Recall theo FraudType @ review 5% đối với Track B	6
Bảng 7 Ma trận quyết định phối hợp đa nghiệp vụ (KYC, Fraud, Credit)	8
Bảng 8 Tỷ lệ phân bổ hành động (Action Rates) trên dữ liệu Holdout	8
Bảng 9 Chỉ số PSI kiểm tra độ ổn định của các tính năng quan trọng	9
Bảng 10 Chẩn đoán rủi ro định kiến (Proxy-bias) trên các phân khúc vận hành	10
Bảng 11 Bảng xếp hạng giá trị đóng góp tính năng (Global SHAP Value)	11

1. Tóm tắt

Repo `VDT_VDS_2026` triển khai bài toán Device Trust Score (DTS): hiểu nghiệp vụ, phân tích dữ liệu, xây feature theo 4 trụ cột: Device Integrity, SIM Stability, Behavioral Consistency và Identity Confidence; thử nghiệm Track A unsupervised, huấn luyện Track B supervised, calibration xác suất fraud, chuyển xác suất sang scorecard DTS 0-1000, và hoàn thiện các artifact vận hành tuần 4.

DTS là điểm tin cậy thiết bị trên thang 0-1000. Điểm cao nghĩa là đáng tin hơn; xác suất gian lận `P_fraud` cao thì DTS thấp. Trong kết quả cuối kỳ, Track B supervised là hướng scoring chính vì có nhãn `FraudFlag`, có thể đo trực tiếp Precision/Recall tại review-rate 5%, có calibration xác suất và có reason codes cho reviewer.

Model `xgb_tuned` đạt AUC khoảng 0.954, PR-AUC khoảng 0.797, Brier khoảng 0.0112 và Precision@5% khoảng 0.508. `stacking_tuned` chỉ nhỉnh hơn rất nhỏ, Precision@5% khoảng 0.510 và PR-AUC chênh khoảng 0.0003, nhưng phức tạp hơn để train, deploy và giải thích. Vì vậy final production-friendly model được chọn là `xgb_tuned`.

Các deliverable cuối cùng:

- Final holdout submission: `outputs/supervised/holdout_submission_final.csv`.
- Decision policy: `outputs/supervised/decision_matrix.csv`.
- Thresholds vận hành: `outputs/supervised/decision_thresholds.json`.
- Action-level output: `outputs/supervised/holdout_decision_actions.csv`.
- Feature PSI: `outputs/supervised/feature_psi_report.csv`.
- Fairness/proxy diagnostic: `outputs/supervised/fairness_segment_report.csv`.
- Model card: `outputs/supervised/final_model_card.md`.
- Report tổng hợp: `docs/VDT_final_report.typ`.

2. Bối cảnh nghiệp vụ và mục tiêu

Bài toán Device Trust Score phục vụ ba use cases:

- KYC: rút ngắn eKYC cho nhóm đáng tin, yêu cầu bổ sung xác minh hoặc enhanced review cho nhóm rủi ro.
- Fraud Detection: xếp hạng khách hàng theo rủi ro gian lận và kiểm soát review quanh top 5%.
- Credit Input: dùng DTS như biến phụ trợ/risk overlay trong credit decision, không thay thế credit score và không auto reject tín dụng độc lập.


Điểm quan trọng của bài toán không phải chỉ là tối đa hóa AUC tổng. Fraud có tỷ lệ thấp, train fraud rate là 3.199%, nên một model có thể có ROC-AUC tốt nhưng vẫn không hữu ích ở vùng top-risk mà đội fraud thật sự review. Vì vậy report này ưu tiên PR-AUC, Precision@5%, Recall@5%, calibration và tính vận hành của decision matrix.

3. Dữ liệu, ERD và chất lượng dữ liệu

Repo sử dụng 6 bảng dữ liệu đầu vào được mô tả chi tiết tại Bảng 1. Mối quan hệ giữa các cấu phần dữ liệu này được chuẩn hóa thông qua sơ đồ thực thể quan hệ tại Hình 1.

Bảng 1: Danh sách các bảng dữ liệu hệ thống đầu vào

Bảng	Vai trò
<code>dts_train.csv</code>	51,047 khách hàng train có <code>FraudFlag</code> , <code>FraudType</code> , <code>Churn</code> và các biến thuê bao.
<code>dts_holdout.csv</code>	20,000 khách hàng holdout cần chấm điểm.
<code>sim_events.csv</code>	Sự kiện SIM: activation, sim swap, port-in và ICCID.
<code>device_sessions.csv</code>	Session thiết bị: IMEI, IP, IP type, quốc gia, home cell, rooted flag.
<code>kyc_records.csv</code>	KYC level, điểm match giấy tờ và khuôn mặt.
<code>device_catalog.csv</code>	Catalog TAC, brand, model, OS và device tier.



Hình 1: ERD dữ liệu đầu vào của bài toán Device Trust Score.

Train có 51,047 dòng; holdout có 20,000 dòng. Tỷ lệ fraud train là 3.199%, gồm `sim_swap_ato=499`, `mule=429`, `device_farm=382`, `subscription_fraud=323`, còn lại `none=49,414`. Đây là class imbalance mạnh, đúng đặc trưng bài toán fraud.

Các kết luận data quality chính:

- Missing KYC có ý nghĩa nghiệp vụ, không chỉ là lỗi dữ liệu. Vì vậy các biến như `has_face_score`, `has_iddoc_score`, `face_match_score`, `id_doc_match_score` được giữ lại.
- Shared IMEI là tín hiệu rủi ro quan trọng, không bị xóa như duplicate thông thường. Nó liên quan trực tiếp đến device farm, mule và thiết bị dùng chung.
- Train/holdout có các biến nền tương đồng. Feature PSI trên các feature top SHAP và feature chính đều stable, PSI lớn nhất dưới 0.001.
- Event tables được tổng hợp về cấp `CustomerID`, bảo đảm feature train/holdout cùng logic và không dùng answer key holdout.

4. Feature engineering

Feature engineering được tổ chức thành 4 pillar chiến lược như hiển thị trong Bảng 2.

Bảng 2: Cấu trúc cấu thành 4 trụ cột tính năng (Feature Pillars)

Pillar	Feature tiêu biểu
Identity Confidence	kyc_level_ord, has_face_score, has_iddoc_score, face_match_score, id_doc_match_score
SIM Stability	phone_number_age_days, sim_swap_count_90d, days_since_last_sim_swap, iccid_count, port_in_flag, recent_sim_change_flag
Device Integrity	num_imeis_90d, max_customers_per_imei, shared_imei_flag, rooted_session_ratio, device_tier_min, tac_risk_score
Behavioral Consistency	distinct_ip_count, distinct_country_count, datacenter_ratio, vpn_proxy_ratio, home_cell_ratio, night_session_ratio, geo_velocity_flag

Pipeline sử dụng cửa sổ 7/30/90 ngày, feature graph/shared-device, KYC missing indicators, WOE encoding cho categorical features, và các feature hành vi từ session. Hai snapshot supervised feature cuối cùng đã được tạo:

- outputs/supervised/train_features_supervised.parquet.
- outputs/supervised/holdout_features_supervised.parquet.

Feature engineering này là cầu nối giữa Track A và Track B: những tín hiệu anomaly như shared device, nhiều IP/quốc gia, SIM swap gần đây và KYC yếu được chuyển thành feature supervised có thể học trực tiếp từ label fraud.

5. Track A - Unsupervised

Track A tạo anomaly score và DTS unsupervised từ các tín hiệu thiết bị, SIM, hành vi, identity và graph. Các output chính gồm:

- outputs/anomaly_scores.csv.
- outputs/anomaly_graph_score.csv.
- outputs/dts_unsup_with_pillars.csv.
- outputs/trackA_holdout_submission.csv.
- outputs/unsup_submit/*.csv.

Kết quả so sánh tổng quan hiệu năng các mô hình thuộc Track A được liệt kê ở Bảng 3. Sự suy giảm của mô hình kết hợp (Blend) so với Baseline tại vùng 4-5% rủi ro cao nhất được minh họa trực quan trong tương quan tổng thể tại Hình 2.

Bảng 3: Hiệu năng tổng quát của các thuật toán Unsupervised Track A

Pipeline	AUC	PR-AUC	Precision@5%
Baseline Isolation Forest mentor	0.777	0.391	0.280
Blend LOF + ISO + graph	0.789	0.302	0.227

Blend tốt hơn về AUC tổng nhưng kém hơn về PR-AUC và precision tại review-rate. Đây là bài học chính của Track A: trong fraud detection, model thắng ở AUC chưa chắc thắng ở top 4-5% risk. Track A phù hợp làm early-warning/rule/anomaly layer, nhưng không nên là final fraud scoring duy nhất.

Hiệu suất thu hồi (Recall) chi tiết theo từng loại hình gian lận (FraudType) tại điểm cắt tối ưu 4% được trình bày cụ thể ở Bảng 4.

Bảng 4: Recall theo FraudType @ review 4% đối với Track A

FraudType	Baseline	Blend	Nhận xét
device_farm	79.5%	74.3%	Baseline tốt hơn
mule	28.3%	26.3%	Baseline tốt hơn nhẹ
sim_swap_ato	48.0%	17.9%	Blend làm giảm mạnh
subscription_fraud	0.7%	10.1%	Blend tốt hơn nhưng vẫn thấp

Khoảng yếu của anomaly detection nằm ở mule và subscription fraud: các archetype này được thiết kế để trông giống người dùng bình thường, không tạo cực trị rõ trên feature phân phối.

6. Track B - Supervised


Track B dùng nhân fraud để train các model supervised. Các output chính gồm:

- outputs/supervised/submit/*.csv.
- outputs/supervised/supervised_holdout_calibrated_scores.csv.
- outputs/supervised/supervised_calibration_reliability_curve.csv.
- outputs/supervised/supervised_global_shap_importance.csv.
- outputs/supervised/supervised_holdout_reason_codes.csv.

Kết quả phân tích 5 mô hình cốt lõi được thống kê tại Bảng 5.

Bảng 5: Hiệu năng định lượng các mô hình Supervised Track B

Model	AUC	PR-AUC	Brier	Precision@5%
xgb_tuned	0.954	0.797	0.0112	0.508
stacking_tuned	0.957	0.797	0.0112	0.510
gbm_tuned	0.959	0.792	0.0115	0.410
lgbm_tuned	0.953	0.790	0.0113	0.463
logistic_tuned	0.932	0.673	0.0158	0.445




Hình 2: So sánh metric tổng hợp giữa Track A baseline, Track A blend và Track B XGB.

Khả năng bao phủ lỗi sai của các thuật toán Supervised được phân rã theo Bảng 6. Biểu đồ so sánh trực quan PR-AUC và mức độ chính xác Precision@5% được thể hiện chi tiết tại Hình 3.

Bảng 6: Recall theo FraudType @ review 5% đối với Track B

FraudType	logistic_tuned	gbm_tuned	xgb_tuned
device_farm	84.2%	90.1%	87.1%
mule	61.8%	77.6%	75.0%
sim_swap_ato	67.6%	81.0%	77.7%
subscription_fraud	68.8%	86.2%	86.2%




Hình 3: PR-AUC và Precision@5% của các mô hình Track B.

Track B vượt rõ Track A ở các archetype khó. Với mule, supervised đạt khoảng 75-77.6% recall trong khi Track A chỉ khoảng 26-28%. Với subscription fraud, supervised đạt 86.2% trong khi Track A chỉ 0.7-10.1%. Đây là bằng chứng định lượng cho giá trị của nhãn fraud.

7. Final model, calibration và DTS scorecard

Final model được chọn là xgb_tuned nhờ sự cân bằng tối ưu. Luồng biến đổi điểm số tuân thủ nghiêm ngặt quy trình: raw P_fraud -> calibrated P_fraud -> PDO score -> DTS 0-1000. Sự sai lệch xác suất của mô hình sau căn chỉnh (calibration) được mô tả bằng đường cong tin cậy tại Hình 4.



Hình 4: Reliability curve của xgb_tuned: xác suất sau calibration so với fraud rate thực tế theo bin.

Từ reliability table của `xgb_tuned`, calibration gap lớn nhất nằm ở bin raw probability `[0.6, 0.7]`: mean calibrated probability 0.2654, actual fraud rate 0.2475, gap khoảng 0.0179. Gap này nhỏ ở mức dùng được cho risk input, nhưng `P_fraud` vẫn không phải quyết định credit độc lập.

8. Decision matrix cho KYC, Fraud Detection và Credit Input

Hệ thống luật ra quyết định (Decision Matrix) tích hợp đa luồng nghiệp vụ được thiết lập tự động hóa tại Bảng 7. Các ngưỡng trong decision matrix được thiết kế theo hướng distribution-based policy thresholds thay vì hard-code điểm tuyệt đối. Với Fraud Detection, ngưỡng manual review được lấy tại quantile 95% của `P_fraud` để đảm bảo tổng tỷ lệ review/decline không vượt quá 5%, phù hợp với ràng buộc vận hành của đề bài. Các ngưỡng còn lại như top 30% DTS cho fast eKYC, bottom 5% DTS cho enhanced review, top 20% `P_fraud` cho step-up authentication được xem là thresholds thử nghiệm ban đầu, phản ánh risk appetite và năng lực vận hành ban đầu. Khi triển khai thực tế, các ngưỡng này cần được điều chỉnh dựa trên cost, capacity, observed fraud rate và phản hồi nghiệp vụ.


Bảng 7: Ma trận quyết định phối hợp đa nghiệp vụ (KYC, Fraud, Credit)

Use case	Rule	Action	Ghi chú
KYC	<code>DTS >= 1000</code>	<code>fast ekyc</code>	<code>kyc_fast_cutoff = q70(DTS)</code> . Vì nhiều điểm DTS bằng 1000 nên action rate là 52.96%.
KYC	<code>DTS <= 766</code>	<code>reject or enhanced review</code>	<code>kyc_reject_cutoff = q05(DTS)</code> , rate 5.13%.
KYC	<code>otherwise</code>	<code>additional verification</code>	Vùng giữa.
Fraud	<code>P_fraud >= 1.0</code>	<code>decline or block</code>	<code>fraud_decline_cutoff_p = q99.5(P_fraud)</code> , rate 1.06%; cần strong fraud signals/business approval.
Fraud	<code>P_fraud >= 0.09120521</code>	<code>manual review</code>	<code>fraud_review_cutoff_p = q95(P_fraud)</code> , manual review rate 4.06%.
Fraud	<code>P_fraud >= 0.00826757</code>	<code>step up authentication</code>	<code>fraud_stepup_cutoff_p = q80(P_fraud)</code> .
Fraud	<code>otherwise</code>	<code>approve</code>	Không vào step-up/review theo policy hiện tại.
Credit	<code>DTS >= 1000</code>	<code>normal credit flow with low device risk</code>	<code>credit_high_cutoff = q70(DTS)</code> .
Credit	<code>DTS <= 858</code>	<code>fraud review or step up before credit decision</code>	<code>credit_low_cutoff = q10(DTS)</code> ; không auto reject tín dụng độc lập.
Credit	<code>otherwise</code>	<code>use dts as auxiliary credit feature</code>	DTS là feature bổ sung/risk overlay.

Tỷ lệ phân bổ hành động thực tế trên tập dữ liệu Holdout được tổng hợp tại Bảng 8 và trực quan hóa tại Hình 5.

Bảng 8: Tỷ lệ phân bổ hành động (Action Rates) trên dữ liệu Holdout

Action	Rate
<code>approve</code>	78.04%
<code>step_up_authentication</code>	16.83%
<code>manual_review</code>	4.06%
<code>decline_or_block</code>	1.06%
<code>manual_review_or_decline</code>	5.13%



Hình 5: Tỷ lệ action fraud trên holdout final sau khi áp dụng decision matrix.

Manual review riêng thấp hơn 5%; manual review cộng decline/block là 5.13% do nhiều score bị tie tại ngưỡng. Đây là điểm cần ghi rõ cho vận hành: nếu business bắt buộc tổng manual + block không vượt đúng 5.00%, cần tie-breaker deterministic theo CustomerID hoặc ranking phụ.


9. PSI và stability

Chỉ số ổn định tính năng (Feature PSI) liên tầng dữ liệu Train và Holdout được thống kê chi tiết ở Bảng 9.

Bảng 9: Chỉ số PSI kiểm tra độ ổn định của các tính năng quan trọng

Feature	PSI	Status
MonthlyMinutes	0.000937	stable
total_sessions	0.000860	stable
ServiceArea_woe	0.000816	stable
night_session_ratio_30d	0.000620	stable
avg_sessions_per_day	0.000607	stable
home_cell_ratio	0.000583	stable
days_since_first_seen	0.000548	stable
id_doc_match_score	0.000536	stable

Phân phối trực quan của các biến số này được phác họa tại Hình 6.



Hình 6: Top feature PSI train-vs-holdout. Tất cả feature trong hình đều ở trạng thái stable.

Quy ước diễn giải:

- $PSI < 0.10$: stable.
- $0.10 \leq PSI < 0.25$: moderate shift.
- $PSI \geq 0.25$: significant shift.


Với score PSI với xgb_tuned giữa train với holdout, kết quả cũng stable: P_fraud PSI = 0.025896 và DTS PSI = 0.010133.

10. Fairness/proxy-bias diagnostic

Báo cáo chẩn đoán định kiến phân lớp (Proxy-bias) theo phân khúc khách hàng chiến lược được thống kê cụ thể tại Bảng 10 và cấu trúc tỷ lệ đánh giá thủ công tương ứng được đặt tại Hình 7.

Bảng 10: Chẩn đoán rủi ro định kiến (Proxy-bias) trên các phân khúc vận hành

Segment	Count	Mean P_fraud	Mean DTS	Review/block rate
all_customers	20000	0.0333	949.7	5.13%
frequent_roaming	1205	0.0338	946.3	6.06%
recent_port_in	2087	0.0689	908.8	9.92%
low_device_tier	2902	0.0305	951.5	4.72%
shared_device	1059	0.2070	764.3	28.52%
high_legit_usage	1997	0.0260	961.6	3.66%



Hình 7: Review/block rate theo các segment fairness/proxy-bias diagnostic.


Nhóm shared device có rủi ro cao nhất: mean $P_{\text{fraud}}=0.2070$, mean DTS 764.3 và review/block rate 28.52%. Đây là tín hiệu hợp lý với fraud farm/mule, nhưng vẫn cần reason codes để tránh phạt oan các trường hợp dùng chung thiết bị hợp pháp. Nhóm recent port-in cũng có risk cao hơn nền, review/block rate 9.92%. Nhóm high legitimate usage có review/block rate thấp hơn nền, cho thấy model không đơn giản phạt khách hàng hoạt động nhiều.

11. Explainability và reason codes

Tầm quan trọng toàn cục của các nhóm tính năng (Global SHAP Importance) được liệt kê có thứ tự tại Bảng 11 và biểu diễn đồ họa tương ứng tại Hình 8.

Bảng 11: Bảng xếp hạng giá trị đóng góp tính năng (Global SHAP Value)

Rank	Feature	Mean abs SHAP
1	distinct_ip_count	0.388451
2	ServiceArea_woe	0.258642
3	id_doc_match_score	0.240804
4	home_cell_ratio	0.146695
5	distinct_country_count	0.136749
6	days_since_last_sim_swap	0.135995
7	face_match_score	0.131730
8	max_customers_per_imei	0.121875
9	night_session_ratio	0.117994
10	observed_device_days	0.092208



Hình 8: Top 10 global SHAP feature importance từ output explainability.

Nhóm feature quan trọng trải đều trên behavior, identity, SIM và device. Điều này phù hợp thiết kế 4 pillar: model không chỉ dựa vào một biến proxy đơn lẻ, mà kết hợp tín hiệu đa nguồn. Reason codes ở `outputs/supervised/supervised_holdout_reason_codes.csv` phục vụ reviewer khi một khách hàng bị đưa vào manual review hoặc decline/block.

12. Câu hỏi checkpoint week 4

Câu hỏi: Nếu kẻ gian biết logic của DTS, chúng sẽ né như thế nào và hệ thống cần giám sát chỉ số gì để phát hiện?

Nếu kẻ gian biết logic DTS, họ có thể né bằng cách:

- Giữ thiết bị ổn định giả.
- Tránh SIM swap gần thời điểm mở tài khoản.
- Dùng residential IP thay vì datacenter/VPN/proxy.
- Hạn chế shared IMEI rõ ràng.
- Nâng KYC giả hoặc mượn danh tính tốt.
- Bắt chước hành vi home-cell và giảm geo-velocity.

Vì vậy DTS không nên là rule tĩnh. Monitoring cần theo dõi:

- Feature drift: PSI cho top SHAP features.
- Score/action drift: phân bố DTS, `P_fraud`, action KYC/fraud/credit.
- Calibration drift khi label đến.
- Fraud rate theo DTS bucket.
- Review precision và recall theo FraudType.
- Segment drift cho roaming, port-in, low device tier và shared device.

13. Kết luận cuối kỳ

Repo đã hoàn thành đầy đủ chuỗi xử lý từ dữ liệu đến artifact vận hành. Track A cho thấy giá trị của anomaly detection trong early-warning, đặc biệt với device farm, nhưng yếu ở mule và subscription fraud. Track B supervised vượt rõ baseline và là hướng final scoring. `xgb_tuned` được chọn vì hiệu năng gần stacking nhưng đơn giản, dễ deploy và dễ giải thích hơn.

DTS cuối cùng có thể dùng cho ba use case:

- KYC: fast eKYC, additional verification, reject/enhanced review theo quantile DTS.
- Fraud Detection: approve, step-up, manual review, decline/block theo quantile `P_fraud`.
- Credit Input: dùng DTS như auxiliary feature/risk overlay, không auto reject tín dụng độc lập.

Các artifact cuối cùng trong repo đã cho phép tái tạo: final submission, decision matrix, thresholds JSON, action CSV, feature PSI, fairness segment report, SHAP importance, reason codes và model card.

14. Câu hỏi phản biện

14.1. Tại sao Track A AUC cao hơn nhưng PR-AUC/precision lại thấp hơn?

ROC-AUC và PR-AUC đo hai khía cạnh khác nhau của mô hình.

ROC-AUC đo khả năng xếp hạng tổng thể giữa hai lớp. Nó trả lời câu hỏi: nếu lấy ngẫu nhiên một khách hàng fraud và một khách hàng non-fraud, mô hình có chấm điểm khách fraud cao hơn không? Chỉ số này được tính trên toàn bộ các threshold, thông qua quan hệ giữa:

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

Trong bài toán fraud detection, số lượng non-fraud rất lớn nên "TN" lớn. Vì vậy "FPR" có thể vẫn nhỏ dù số lượng "FP" thực tế không hề ít. Do đó, ROC-AUC có thể nhìn tốt ở mức tổng thể, nhưng chưa chắc phản ánh tốt chất lượng tại vùng rủi ro cao cần review.

Ngược lại, PR-AUC tập trung vào lớp fraud, thông qua Precision và Recall:

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

Precision trả lời trực tiếp câu hỏi nghiệp vụ: trong số khách hàng bị cảnh báo rủi ro cao, có bao nhiêu người thực sự là fraud? Đây là chỉ số quan trọng hơn trong bài này vì đội vận hành chỉ có thể review khoảng 4% – 5% khách hàng rủi ro cao nhất.

Kết quả Track A cho thấy mô hình Blend có ROC-AUC tăng từ 0.777 lên 0.789, nghĩa là khả năng ranking tổng thể cải thiện nhẹ. Tuy nhiên, PR-AUC giảm từ 0.391 xuống 0.302, và Precision@5% giảm từ 0.280 xuống 0.227. Điều này cho thấy Blend tốt hơn ở một số vùng threshold tổng quát, nhưng lại kém hơn ở đúng vùng top 5% rủi ro cao nhất - vùng được sử dụng thật trong vận hành.

Kết luận: Với ràng buộc review khoảng 5%, PR-AUC và Precision@5% quan trọng hơn ROC-AUC. Dù Blend có AUC cao hơn, Baseline Isolation Forest vẫn phù hợp hơn ở điểm vận hành thực tế vì đưa được nhiều fraud thật hơn vào nhóm khách được review. Bên cạnh đó có thể đánh giá thêm các mô hình iso và lof đơn lẻ để so sánh và chọn ra mô hình phù hợp.

14.2. Nguyên nhân sim_swap_ato giảm mạnh trong Track A blend là gì?

Do holdout không có nhãn, phần truy nguyên nhân được đánh giá trên train có nhãn (51,047 dòng, 499 case sim_swap_ato) bằng đúng feature/model Track A đã dùng trước đó: IsolationForest, LOF, blend 90/10, và graph adjustment. Kết quả AUC, recall cho riêng sim_swap_ato:

Component	AUC	Recall@4%
iso	0.758	19.0%
lof	0.823	22.4%
blend_90_10	0.778	24.8%
graph_adjusted	0.775	22.0%

Kết quả này cho thấy thành phần kéo sim_swap_ato xuống rõ nhất là graph adjustment. Tín hiệu neighbor_anomaly_rank_pct gần như không tách được sim_swap_ato trên train: AUC chỉ 0.537 và Recall@4% chỉ 3.6%. Khi đưa graph vào công thức graph_adjusted = 0.90 * rank(blend) + 0.10 * neighbor_rank, Recall@4% giảm từ 24.8% của blend_90_10 xuống 22.0%.

Trọng số blend hiện tại 0.90 * iso + 0.10 * lof cũng không tối ưu nếu mục tiêu riêng là sim_swap_ato. Trên train, sweep trọng số cho thấy vùng cân bằng hơn tốt hơn rõ: iso_weight=0.50, lof_weight=0.50 đạt Recall@4% 31.9% và AUC 0.833. Điều này nghĩa là LOF đang mang thêm tín hiệu hữu ích cho sim_swap_ato, nhưng bị underweight ở cấu hình 90/10.

Trên holdout, vì không có nhãn nên không thể tính lại recall thật theo từng component. Tuy nhiên do graph-adjusted đã làm giảm tín hiệu `sim_swap_ato` trên train, việc recall `sim_swap_ato` ở holdout giảm mạnh là nhất quán với phân tích này. Nếu tối ưu riêng cho `sim_swap_ato`, nên tăng trọng số LOF và không trộn graph neighbor vào cùng score, hoặc dùng graph như flag/rule riêng thay vì cộng tuyến tính vào anomaly score, có thể so sánh thêm với từng mô hình thành phần đơn lẻ để đánh giá.

14.3. Nếu chỉ chọn baseline unsupervised hoặc blend unsupervised để production ngay, chọn cái nào?

Chọn baseline Isolation Forest. Lý do là PR-AUC 0.391 cao hơn 0.302, Precision@5% 0.280 cao hơn 0.227, Precision@4% 0.333 cao hơn 0.266 và Recall@4% 0.416 cao hơn 0.333. Production fraud review cần hiệu quả tại top review-rate, không cần pipeline phức tạp hơn nếu metric vận hành kém hơn.

14.4. Vì sao mule và subscription fraud gần như vô hình với anomaly detection?

(Thực ra em cũng đã đề cập ở report trước rồi ạ, các report nằm trong folder docs/ trên repo ạ).

Mule account có thể không phải outlier đơn lẻ: mỗi tài khoản chỉ mang một phần tín hiệu như shared-device, mobility hoặc night activity, mà các tín hiệu này cũng xuất hiện ở hộ gia đình dùng chung máy, người dùng di chuyển nhiều hoặc power user. Nếu mạng mule phân tán và mỗi node chỉ hơi bất thường, IF/LOF cấp khách hàng khó bắt; cần graph/community detection và risk propagation.

Subscription fraud thường được thiết kế gần normal: SIM mới, thiết bị mới, KYC trung bình, nhưng không nhất thiết cực đoan. Trong môi trường không nhãn và thiếu tín hiệu payment, early delinquency, chargeback hoặc non-payment, unsupervised khó phân biệt khách hàng mới hợp pháp với fraud mới khởi tạo. Nhóm này có thể nằm trong vùng mật độ bình thường nên không bị anomaly model flag.

Track A chỉ đạt khoảng 26-28% recall cho mule và 0.7-10.1% cho subscription fraud ở review 4%, trong khi supervised đạt 75-77.6% cho mule và 86.2% cho subscription fraud. Khoảng cách này chứng minh các archetype khó cần label hoặc graph tín hiệu mạnh.

14.5. Có nên đưa stacking vào production khi không tốt hơn XGBoost đáng kể?

Em sẽ **không đề xuất dùng `stacking_tuned` làm production model mặc định**. Lý do là mức cải thiện so với `xgb_tuned` quá nhỏ so với độ phức tạp vận hành.

Về số liệu, `stacking_tuned` đạt PR-AUC khoảng 0.797 và Precision@5% khoảng 0.510, gần như tương đương `xgb_tuned` với PR-AUC khoảng 0.797 và Precision@5% khoảng 0.508. Chênh lệch PR-AUC chỉ khoảng 0.0003, không đủ lớn để biện minh cho việc dùng mô hình phức tạp hơn.

Khi chọn model production, nếu xét thêm: hiệu năng tại top 5% review, calibration, độ ổn định, khả năng giải thích, chi phí triển khai, khả năng retrain và monitoring, ở các tiêu chí này, `xgb_tuned` có lợi thế vì là mô hình đơn, dễ deploy, dễ debug và có thể dùng SHAP trực tiếp để tạo reason codes.

Vì vậy, em đề xuất dùng `xgb_tuned` làm champion model cho production, còn `stacking_tuned` giữ vai trò challenger hoặc benchmark offline. Chỉ nên đưa stacking vào production nếu nó tạo ra cải thiện rõ ràng và ổn định hơn ở các metric vận hành như Precision@5%, recall trong nhóm review, calibration và stability.

14.6. GBM và XGB PR-AUC gần nhau nhưng Precision@5% lệch lớn nói lên điều gì?

`gbm_tuned` và `xgb_tuned` có PR-AUC khá gần nhau: `gbm_tuned` đạt khoảng 0.792, còn `xgb_tuned` đạt khoảng 0.797. Nếu chỉ nhìn PR-AUC, hai mô hình có vẻ gần tương đương.

Tuy nhiên, tại điểm vận hành thật, sự khác biệt lại rất lớn. Precision@5% của `gbm_tuned` chỉ khoảng 0.410, trong khi `xgb_tuned` đạt khoảng 0.508. Điều này nghĩa là nếu cùng review top 5% khách hàng rủi ro cao nhất, XGBoost đưa được nhiều fraud thật hơn vào hàng đợi review.

Điều này cho thấy một metric tổng như PR-AUC không đủ để chọn model production. PR-AUC đo chất lượng trên nhiều ngưỡng, nhưng business chỉ vận hành ở một vùng rất cụ thể: top 5% khách hàng được review. Vì vậy, model cuối cần được chọn dựa trên cả metric tổng và metric tại operating point thật, đặc biệt là Precision@5%.

Với stakeholder không rành kỹ thuật, em sẽ giải thích như sau: hai model nhìn tổng thể khá giống nhau, nhưng khi đội fraud chỉ có thể kiểm tra 5% khách hàng, `xgb_tuned` giúp danh sách review nhiều fraud thật hơn. Ví dụ, trong mỗi 1000 khách được review, `xgb_tuned` tìm được khoảng 508 fraud thật, còn `gbm_tuned` chỉ khoảng 410. Vì vậy, XGBoost giúp dùng cùng một công review nhưng bắt được nhiều fraud hơn.

Kết luận: Em sẽ chọn `xgb_tuned` làm model cuối vì nó không chỉ có PR-AUC tốt, mà còn vượt trội rõ ràng tại điểm vận hành quan trọng nhất là Precision@5%.

14.7. Vì sao logistic có $\text{Corr}(\text{P_fraud}, \text{DTS})$ yếu hơn các model phi tuyến?

Trên holdout calibrated scores, logistic có Pearson $\text{Corr}(\text{P_fraud}, \text{DTS})$ yếu hơn rõ so với nhóm tree/stacking:

Model	Pearson Corr	Spearman Corr
<code>logistic_tuned</code>	-0.875	-0.947
<code>xgb_tuned</code>	-0.927	-0.938
<code>gbm_tuned</code>	-0.931	-0.789
<code>lgbm_tuned</code>	-0.929	-0.880
<code>stacking_tuned</code>	-0.925	-0.842

PDO score được tính từ log-odds nên quan hệ xác suất-score vẫn phải đi ngược chiều: `P_fraud` càng cao thì DTS càng thấp. Vì vậy các corr đều âm. Điểm khác biệt là logistic chỉ đạt Pearson khoảng -0.875, thấp hơn `xgb_tuned` -0.927, `gbm_tuned` -0.931, `lgbm_tuned` -0.929 và `stacking_tuned` -0.925. Điều này cho thấy quan hệ tuyến tính giữa xác suất calibrated và DTS của logistic kém chặt hơn sau calibration và clipping score 0-1000.

Tuy nhiên Spearman của logistic vẫn rất mạnh (-0.947), nên vấn đề không phải ranking bị đảo. Cách hiểu đúng là logistic vẫn giữ thứ tự rủi ro khá tốt, nhưng do mô hình tuyến tính không bắt tốt interaction phi tuyến như shared device, KYC missing, geo-velocity, SIM swap và IP behavior, độ phân giải/shape của xác suất sau calibration không mượt bằng các model phi tuyến.

14.8. Calibration gap lớn nhất ở final model là bin nào và có ảnh hưởng credit input không?

Với `xgb_tuned`, gap lớn nhất trong reliability table nằm ở bin raw probability (0.6, 0.7]: mean calibrated probability là 0.2654, actual fraud rate là 0.2475, gap khoảng 0.0179.

Gap này nhỏ, nên không đủ để loại bỏ `P_fraud`/DTS khỏi credit input. Tuy nhiên, DTS chỉ nên được dùng như tín hiệu phụ trợ về fraud/device risk, không phải rule tự động từ chối tín dụng. Nói cách khác, DTS có thể là một feature trong credit model hoặc dùng để yêu cầu fraud/eKYC check bổ sung, nhưng không nên áp dụng rule kiểu DTS thấp thì tự động reject khoản vay, vì DTS không đo trực tiếp khả năng trả nợ.

14.9. Nếu chỉ đủ ngân sách triển khai rule-based/unsupervised hoặc supervised, nên chọn lộ trình nào?

Em sẽ không chọn một hướng duy nhất cho cả ba mục đích, vì KYC, fraud detection và credit input có mức độ rủi ro và yêu cầu label khác nhau.

Trong giai đoạn đầu, em đề xuất ưu tiên rule-based/unsupervised cho KYC và fraud detection. Lý do là hai use case này cần phản ứng real-time, trong khi supervised model cần nhân fraud confirmed đủ tin cậy trong 6-12 tháng. Rule-based/unsupervised có thể triển khai sớm để phát hiện các tín hiệu rõ ràng như SIM swap gần đây, shared device, rooted device, datacenter IP, nhiều IP/quốc gia bất thường hoặc KYC yếu. Cách này chưa tối ưu bằng supervised model, nhưng phù hợp để giảm rủi ro ngay và đồng thời tạo hàng đợi review để thu thập nhân.

Với fraud detection, em sẽ dùng rule-based/unsupervised như lớp phòng thủ ban đầu và label collection engine. Sau 6-12 tháng, khi đã có nhân fraud confirmed từ manual review, chargeback hoặc investigation, công ty nên chuyển dần sang supervised model vì supervised model học được tổ hợp tín hiệu tốt hơn và cho performance cao hơn. Tuy nhiên, rule-based vẫn nên được giữ lại như guardrail cho các pattern cực rõ hoặc fraud pattern mới chưa có nhiều nhân.

Với KYC, em cũng có thể dùng rule-based/unsupervised ngay từ đầu để chia luồng: khách rủi ro thấp đi fast eKYC, khách nghi ngờ đi additional verification, và nhóm cực rủi ro đi enhanced review. Tuy nhiên, không nên reject tự động chỉ dựa vào anomaly score, vì nhóm khách hợp pháp như người vừa port-in, đi nước ngoài hoặc dùng thiết bị giá rẻ có thể bị phạt oan.

Riêng với credit input, em sẽ thận trọng hơn. Trong giai đoạn chưa có supervised model và calibration đủ tốt, DTS chỉ nên dùng như tín hiệu phụ trợ về fraud/device risk, không phải rule tự động từ chối tín dụng. Nghĩa là

DTS thấp có thể kích hoạt fraud/eKYC check bổ sung trước khi xét credit, nhưng không nên dùng rule kiểu DTS thấp -> reject khoản vay, vì DTS không đo trực tiếp khả năng trả nợ.

Tóm lại, lộ trình em đề xuất là: triển khai rule-based/unsupervised trước cho KYC và fraud detection để có khả năng real-time và thu thập nhãn; sau 6-12 tháng dùng nhãn confirmed để xây dựng supervised model cho fraud detection và làm input phụ trợ cho credit. Với credit, chỉ nên dùng DTS như risk overlay hoặc auxiliary feature, không dùng làm quyết định tín dụng độc lập.

14.10. Khi triển khai thật không có answer key ngay, monitoring model drift thế nào?

Trước khi có label, em sẽ theo dõi các chỉ số không cần nhãn như feature PSI, phân phối P_fraud/DTS, phân phối action, tỷ lệ manual_review, step_up và decline/block. Ngoài ra, em sẽ theo dõi drift theo segment như khách vừa port-in, khách dùng shared device, roaming, low device tier và nhóm KYC yếu.

Em cũng sẽ monitor riêng phân phối của các tín hiệu dễ bị đối tượng gian lận thích nghi hoặc né tránh, ví dụ shared_imei, SIM swap, port-in, VPN/datacenter IP, rooted device và KYC missing. Nếu các tín hiệu này giảm hoặc tăng bất thường, đó có thể là dấu hiệu fraudster đang thay đổi chiến thuật hoặc dữ liệu đầu vào đã bị drift.

Khi label đến trễ từ manual review, confirmed fraud, chargeback hoặc investigation, em sẽ đo lại các chỉ số supervised như review precision, fraud rate theo DTS bucket, calibration drift/Brier score, recall theo FraudType, và false positive rate theo segment. Đặc biệt, em sẽ tách riêng mule và subscription_fraud vì đây là hai archetype khó với anomaly detection: tín hiệu thường không quá cực đoan và dễ giống khách hàng hợp pháp.

Tóm lại, khi chưa có answer key, em dùng feature/score/action/segment monitoring để phát hiện sớm drift. Khi label trễ xuất hiện, em dùng lại các metric supervised để xác nhận model có thật sự xuống hiệu năng hay không.